

INFORME FINAL

Clase 4 — Modelos Supervisados II: SVM y Redes Neuronales (MLP)
Odilón Nolf Sánchez | CI: 4189076

1. Resumen Ejecutivo

Este laboratorio exploró dos familias de clasificadores no lineales — Máquinas de Soporte Vectorial (SVM con kernel RBF) y Perceptrones Multicapa (MLP) — sobre datasets sintéticos de geometría no lineal (moons y circles). Se entrenaron, evaluaron y compararon ambos modelos, se realizó un análisis de sensibilidad a hiperparámetros y se completaron cinco ejercicios prácticos que cubren desde búsqueda en cuadrícula hasta regularización L2 y reducción de dimensionalidad con PCA.

2. Modelos y Datasets Utilizados

2.1 Datasets

Se generaron dos conjuntos de datos con scikit-learn:

- Moons (n=500, noise=0.2): dos clases con forma de media luna, con ligera superposición en la zona central.
- Circles (n=500, noise=0.15, factor=0.5): clases concéntricas, separadas radialmente pero con ruido en el borde.

Ambos datasets fueron divididos en 70 % entrenamiento y 30 % prueba, con escala estándar aplicada sobre el conjunto de entrenamiento.

2.2 Modelos

- SVM RBF (C=1, gamma='scale', probability=True): aprovecha el kernel gaussiano para separar clases no linealmente separables mediante transformación implícita al espacio de características.
- MLP (hidden_layer_sizes=(100,), activation='relu', solver='adam', max_iter=1000): red neuronal de una capa oculta optimizada con Adam.

3. Resultados Principales

3.1 Accuracy en conjunto de prueba

Dataset	SVM RBF	MLP (1 capa)
Moons	0.940	0.953
Circles	0.907	0.900

En moons el MLP superó marginalmente al SVM. En circles ambos alcanzaron rendimiento equivalente (~ 0.90), confirmando que el kernel RBF es suficientemente expresivo para capturar fronteras circulares.

4. Análisis de Hiperparámetros

4.1 Sensibilidad C y gamma (SVM — moons)

Se evaluaron 9 combinaciones ($C \in \{0.1, 1, 10\} \times \gamma \in \{\text{'scale'}, 0.5, 1.0\}$). Valores altos de C combinados con gamma grande generan fronteras más ajustadas y mayor riesgo de sobreajuste; $C=1$ con $\gamma=\text{'scale'}$ ofrece el mejor equilibrio entre sesgo y varianza en este dataset.

4.2 GridSearchCV (Ejercicio 1)

Se amplió la búsqueda a $C \in \{0.1, 1, 10, 100\} \times \gamma \in \{0.001, 0.01, 0.1, 0.5, 1, \text{'scale'}\}$ con validación cruzada 5-fold. La mejor combinación encontrada mejoró la accuracy de prueba con respecto al modelo por defecto, y su frontera de decisión mostró menor incertidumbre en la zona de superposición.

5. Ejercicios Prácticos

Ejercicio 2 — Arquitecturas MLP en circles

Se compararon seis arquitecturas (1 y 2 capas ocultas, entre 50 y 200 unidades):

Arquitectura	Accuracy	Tendencia
1 capa (50)	~ 0.88	Menor capacidad
1 capa (100)	~ 0.90	Buen equilibrio
1 capa (200)	~ 0.91	Mayor capacidad, más lento
2 capas (100,100)	~ 0.91	Mejor generalización

Aumentar la profundidad (2 capas) no siempre mejora la accuracy, pero estabiliza el aprendizaje.

Ejercicio 3 — Early Stopping y Regularización L2

Activar `early_stopping=True` detuvo el entrenamiento anticipadamente, reduciendo el riesgo de sobreajuste sin pérdida significativa de accuracy. Agregar `alpha=0.01` (regularización L2) disminuyó levemente la accuracy de prueba en circles ($0.90 \rightarrow 0.90$) pero produjo un patrón de error diferente: menos falsos positivos (2 vs 5) pero más falsos negativos (13 vs 9), indicando una frontera más conservadora hacia la clase exterior.

Ejercicio 4 — PCA + Clasificación

Sobre un dataset sintético de 5 características se aplicó PCA a 2 componentes para permitir la visualización de fronteras de decisión. Tanto SVM como MLP entrenados en el espacio proyectado mantuvieron accuracy competitiva, demostrando que los 2 primeros componentes principales capturan la mayoría de la varianza discriminante.

Ejercicio 5 — Comparación Cuantitativa

Análisis de matrices de confusión y métricas F1 para los dos datasets:

- Moons: errores concentrados en la zona de superposición entre las dos lunas. MLP con F1 ligeramente superior.
- Circles: SVM más equilibrado (5 FP / 9 FN); MLP con L2 más selectivo (2 FP / 13 FN). Los errores ocurren principalmente en el borde del círculo interior.

6. Conclusiones

- Ambos modelos (SVM RBF y MLP) son capaces de capturar fronteras no lineales complejas con accuracy superior al 90 % en los datasets evaluados.
- SVM con kernel RBF ofrece convergencia más predecible y depende fuertemente del ajuste de C y gamma; GridSearchCV es indispensable para encontrar la combinación óptima.
- MLP es más flexible en arquitectura pero requiere mayor cuidado con hiperparámetros como el solver, la tasa de aprendizaje y la regularización para evitar sobreajuste.
- Early stopping y regularización L2 son herramientas complementarias: la primera controla las épocas de entrenamiento y la segunda suaviza los pesos, afectando el balance entre falsos positivos y negativos.
- PCA es útil para visualizar y depurar modelos en espacios de alta dimensión, aunque puede descartar varianza relevante si las primeras componentes no capturan toda la estructura discriminante.